

[引用格式] 余满江, 何家伟, 邢博闻. 基于深度强化学习的无人艇集群路径规划 [J]. 水下无人系统学报, 2025, 33(2): 380-388.

基于深度强化学习的无人艇集群路径规划

余满江¹, 何家伟², 邢博闻¹

(1. 上海海洋大学 工程学院, 上海, 201306; 2. 中国船舶及海洋工程设计研究院, 上海, 200011)

摘要: 随着无人艇(USV)在海上搜索领域的广泛应用, 传统的路径规划算法不能满足复杂的救援场景, 会导致局部最优、任务完成率低以及收敛速度慢等情况。为此, 提出了一种 USV 集群协同搜救的路径规划方法。首先, 基于多智能体深度确定性策略梯度算法引入长短期记忆模块, 增强 USV 对路径规划中时序信息的利用能力; 其次, 设计了多层级表征经验池, 提高训练效率和数据利用率, 减少不同经验间的干扰; 最后, 采用随机网络蒸馏作为好奇心机制, 为 USV 探索新区域提供内在奖励, 解决奖励稀疏导致的收敛问题。仿真实验结果表明, 改进后的算法与原始算法相比, 收敛速度提升了约 38.46%, 路径长度也缩短了 27.02%, 且避障能力上有显著提升。

关键词: 无人艇; 深度强化学习; 长短期记忆; 好奇心机制; 路径规划

中图分类号: TJ630.34; U674.941

文献标识码: A

文章编号: 2096-3920(2025)02-0380-09

DOI: 10.11993/j.issn.2096-3920.2024-0179

Unmanned Surface Vessel Cluster Path Planning Based on Deep Reinforcement Learning

YU Manjiang¹, HE Jiawei², XING Bowen¹

(1. College of Engineering, Shanghai Ocean University, Shanghai 201306, China; 2. Marine Design and Research Institute of China, Shanghai 200011, China)

Abstract: With the wide application of unmanned surface vessels(USVs) in the field of maritime search, the traditional path planning algorithms fail to meet the complex rescue scenarios, which can lead to local optimum, low task completion rate, and slow convergence speed. For this reason, a path planning method for USV cluster cooperative search and rescue was proposed. Firstly, a long and short-term memory module was introduced based on the multi-agent deep deterministic policy gradient algorithm to enhance the ability of the USVs to utilize the temporal information in path planning; secondly, a multi-level representational experience pool was designed to improve the training efficiency and data utilization and reduce the interference between different experiences; finally, stochastic network distillation was used as a curiosity mechanism to provide intrinsic rewards for the USVs to explore new regions and solve the convergence due to the sparse rewards. The simulation experiment results show that the improved algorithm improves the convergence speed by about 38.46% compared with the original algorithm, and the path length has been shortened by 27.02%. In addition, the obstacle avoidance ability has been significantly improved.

Keywords: unmanned surface vessel; deep reinforcement learning; long and short-term memory; curiosity mechanism; path planning

收稿日期: 2024-12-30; 修回日期: 2025-02-13; 录用日期: 2025-02-17.

基金项目: 上海市 2022 年度地方院校能力建设项目资助(22010502200).

作者简介: 余满江(1999-), 男, 在读硕士, 研究方向为水面无人艇路径规划.

OPEN ACCESS

0 引言

随着全球对海洋资源的重视和开发, 海洋资源已成为各国竞相探索的战略要地^[1]。近年来, 加快建设海洋强国已上升为我国科技创新的重要战略目标, 推动新型海洋装备研发成为国家科研的重点方向^[2]。其中, 无人艇(unmanned surface vessel, USV)作为一种能够独立执行任务的自动化或远程操控船只^[3], 通过自主导航系统、传感器和无线通信设备实现任务执行和海洋环境适应, 可广泛应用于海洋勘测、环境监测、水域巡逻和海上救援等民用领域, 亦可在军事中承担侦察、反潜、布雷和扫雷等高风险作战任务^[4]。然而, 单一 USV 在面对复杂的海洋环境和多样化的任务时, 其执行力和效率难以满足需求。在海上联合搜救、多目标任务分配等场景中, USV 集群的协同作业显示出更高的任务效率、容错性及优化任务分工的潜力^[5]。因此, 针对 USV 集群的路径规划和任务分配的研究显得尤为重要。

路径规划是保障 USV 安全航行的核心技术之一, 其导航精度和任务效率直接关系到 USV 的智能化水平^[6]。传统算法如 Dijkstra 算法^[7]、A*算法^[8]、遗传算法^[9](genetic algorithm, GA)和蚁群优化(ant colony optimization, ACO)算法^[10]等已被广泛应用于机器人和 USV 的路径规划任务。尽管这些算法在单一智能体路径规划中表现出一定优势, 但由于缺乏自适应学习能力, 无法根据历史经验或环境变化进行优化调整, 难以应对海洋环境中的复杂性和多样化需求。因此, 研究基于多智能体的强化学习方法的重要性日益凸显。

现有研究中, Raibail 等^[11]利用深度强化学习提出了分散式多机器人避障方法, 在策略(Actor)网络-价值(Critic)网络框架下实现协同避障; Li 等^[12]通过多智能体近端策略优化(multi-agent proximal policy optimization, MAPPO)算法解决了多智能体的协同任务; Lowen 等^[13]基于策略梯度提出多智能体深度确定性策略梯度(multi-agent deep deterministic policy gradient, MADDPG)算法, 通过集中训练与分布执行有效提升多智能体学习的稳定性, 但 MADDPG 算法在复杂的环境下, 仍存在收敛速度慢、奖励稀疏且探索不足等问题, 导致智能体频

繁发生碰撞、学习效率低下。针对 MADDPG 算法的不足, 王思琪等^[14]提出在 MADDPG 基础上引入注意力机制, 显著提升了算法效率, 可应用于无人船集群编队任务; 刘鹏等^[15]在 MADDPG 算法中加入了长短期记忆(long-short term memory, LSTM)网络和基于损失的优先级经验回放机制, 提高了训练稳定性, 但是收敛速度需要进一步优化。

针对现有方法中奖励稀疏和模型收敛性差等问题, 文中对 MADDPG 算法进行了优化, 提出以下创新点: 1) 引入 LSTM 模块, 以增强模型长期依赖能力, 提高 USV 集群在复杂动态环境下的协同搜救能力; 2) 引入多层级表征经验池, 能够显著加速训练速度, 减少无关经验对模型的干扰, 从而提升 USV 路径规划的学习效率, 避免重复搜索; 3) 采用随机网络蒸馏(random network distillation, RND)作为好奇心机制, 为 USV 探索新环境提供内在奖励, 从而有效解决奖励稀疏问题并提高任务完成率。文中通过上述改进措施, 为 USV 集群协同联合搜救提供了更加智能、高效的路径规划解决方案。

1 任务描述与建模

1.1 场景描述

在解决 USV 集群协同搜救的路径规划问题时, 将多任务协同和路径规划合为一体, 其中的主要任务就是通过确定遇险目标的精确位置, 以及合理的任务分配, 规划出能够避开障碍物的安全路径, 从而确保 USV 迅速抵达所有目标位置完成救援任务。对于实际的海上联合援救而言, 由于海上环境如海流、风速和障碍物位置等的动态变化, 会对路径规划有较大影响。对于任务分配情况, USV 的实际数量应该会少于目标点的数量, 需要进一步考虑 USV 之间的竞争合作关系。文中的运动环境设置在二维空间中, 假设所有 USV 相同, 所有目标点除位置外的所有信息相同, 有 N 艘 USV, m 个目标点, n 个障碍物。其中第 i 个 USV 的位置向量为 (P_{xi}, P_{yi}) , 第 m 个目标点的位置向量为 (G_{xm}, G_{ym}) , 第 n 个障碍物的位置向量为 (O_{xn}, O_{yn}) 。文中研究的目的是 USV 集群协同完成多个目标任务的同时所得到的奖励回报最大, 且满足如下约束条件:

- 1) 需要到达所有的目标点才算完成任务;

2) USV 在航行过程中要避免与静态障碍物碰撞以及不能超过设置的环境边界;

3) USV 彼此之间认为对方是动态障碍物也要避免碰撞;

4) 在保证路径规划安全性的前提下, 进一步减少 USV 集群整体的路径长度, 从而保证快速到达所有目标点。

1.2 USV 运动学建模

USV 的运动学建模对于 USV 的控制和导航至关重要, 能够准确描述其不同环境下的运动行为, 为路径规划和控制策略的制定提供精确依据。建模时需要在模型的精确度和简化程度之间进行平衡: 如果模型过于精确, 会使建模过程复杂且计算量大; 而过于简化的模型则可能无法准确刻画实际运动状态, 从而降低建模的实际效用。

在具体建模中, 船舶运动一般可以通过 6 个自由度来描述, 包括前进后退(surge)、左右横移(sway)、上下沉浮(heave)、艏摇(yaw)、横摇(roll)和纵摇(pitch)。虽然 6 自由度的运动模型能准确刻画船舶的运动特性, 但由于计算复杂, 在实际应用中较为不便。因此, 在 USV 的路径规划和运动控制中, 仅关注水平面上的运动情况, 并简化为 3 自由度模型。简化后的 3 自由度模型既能描述 USV 的核心运动行为, 又大幅减少了计算复杂性, 更符合实际应用需求, 如图 1 所示。




图 1 USV 的 3 自由度运动模型

Fig. 1 Three-degree-of-freedom kinematic model of a USV

USV 的简化运动模型为

$$\begin{bmatrix} \dot{x}' \\ \dot{y}' \\ \dot{\psi} \end{bmatrix} = \begin{bmatrix} \cos \psi & \sin \psi & 0 \\ \sin \psi & \cos \psi & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mu \\ v \\ \omega \end{bmatrix} \quad (1)$$

式中: x' 和 y' 为 USV 水平面位置; ψ 为航向角; μ 为前进方向上线速度状态向量; v 为横移方向上线速

度状态向量; ω 为航向的角速度状态向量。

1.3 状态空间与动作空间设计

在处理多 USV 的决策问题时, 需要依托马尔可夫决策过程框架来定义状态空间与动作空间。USV 当前的观测状态空间包含 2 个部分: 自身的状态空间 $S(\text{self})$ 和对其他环境感知信息的状态空间 $S(\text{other})$ 。其中, 第 i 艘 USV 的自身状态信息包括位置向量 (P_{xi}, P_{yi}) 、当前线速度向量 (μ_i, v_i) 以及航向角速度向量 ω_i 。其他环境信息的状态空间包括其他 USV 的位置向量 (P_{xj}, P_{yj}) 、障碍物位置向量 (O_{xn}, O_{yn}) 以及目标点位置向量 (G_{xm}, G_{ym}) 。

假设 USV 只能获取环境的局部信息, 其状态空间提供的有用信息有助于其他智能体感知周围环境并做出正确决策。这种设定限制了 USV 对全局信息的获取, 使其决策基于局部观测, 从而更符合实际海上搜救场景中的感知局限性。因此, 第 i 艘 USV 的观测空间元组用 $((P_{xi}, P_{yi}), (P_{xj}, P_{yj}), (O_{xn}, O_{yn}), (G_{xm}, G_{ym}))$ 表示。

为了简化动作空间, 对部分连续动作进行离散处理, 该处理方式可以降低动作空间的维度, 提高决策的准确度, 对 USV 的控制误差影响较小。第 i 艘 USV 的动作由其速度和速度角决定, 速度选择应在最小值与最大值之间, 这与其航向角 ψ 相关, ψ 的取值范围为 $[-90^\circ, 90^\circ]$, 初始角度上有 5 种选择, 即左转 45° , 左转 90° , 右转 45° , 右转 90° , 以及方向不变。为了后续计算方便, 将 USV 沿对角线所走 1 步按照 1.5 步计算, 以此体现 ψ 改变时的 USV 速度变化。

1.4 奖励函数设计

奖励函数的设计是强化学习算法中的关键环节, 其直接影响模型的训练效果和智能体的决策质量。针对 USV 集群路径规划任务, 旨在通过 USV 集群协同合作, 寻找到最优或接近最优的路线来避开障碍物从而达到所有目标点。这一过程中, 为了使 USV 集群获得持续的奖励, 避免出现贪婪、胆怯等异常行为, 克服稀疏奖励带来的效率低下、难以收敛等问题, 可设置如下奖励函数

$$R = R1 + R2 + R3 + R4 + R5 + R6 \quad (2)$$

在奖励函数设计中, 当 USV 集群协同合作抵达所有的目标点时即完成任务, 给予一个正向奖励 $R1$ 。USV 集群当且仅当其在达到所有目标点后

才能获得奖励, 其他时刻无奖励, 这会造成奖励稀疏从而导致降低任务效率的问题。因此需要将总任务分解成多个子任务, 每当完成一个子任务就获得一个奖励, 从而加快收敛速度, 提高 USV 完成联合搜救任务的效率。另外, 在航行过程中, 设置 USV 每走一步给定一个较小的负奖励 $R2$, 通过这种负奖励可以激发其尽快的向目标点方向航行, 从而减少一些不必要的区域探索。USV 与静态障碍物的奖励设置为 $R3$, 若碰到静态障碍物也会给予一个负奖励; 若航行远离静态障碍物会给予一个很小的正奖励, 以此引导其尽量避免碰撞。USV 之间视为动态障碍物奖励, 设置为 $R4$ 。USV 对于边界的奖励设置为 $R5$ 。USV 行驶过程中若航向角发生变化, 给予一个负奖励 $R6$ 。

第 i 艘 USV 位置与第 j 艘 USV 位置的欧式距离为 D_{P_ij} , 第 i 艘 USV 与第 m 个目标点的欧式距离为 D_{G_im} , 第 i 艘 USV 与第 n 个障碍物的欧式距离为 D_{O_in} , 第 i 艘 USV 与边界的距离为 D_{B_i} 。 D_0 为 USV 初始位置与目标点的欧式距离; d_1 为 USV 不会与障碍物发生碰撞的最小安全距离; d_2 为 USV 不需要进行避障控制的最小距离; 将 USV 视为半径为 r 的圆; k 为每一次路径的最大步数; $\Delta\psi$ 为 USV 在相邻 2 个时刻的航向角变化量。

$$R1 = \sum_1^N R1_i \quad (3)$$

$$R1_i = \begin{cases} 10, & 0 \leq D_{G_im} < r \\ 5, & r \leq D_{G_im} < 2r \\ 2.5, & 2r \leq D_{G_im} \leq 4r \\ 0.3 \times (D_0 - D_{G_im}), & D_{G_im} > 4r \end{cases} \quad (4)$$

$$R2 = -0.01k, k \leq 100 \quad (5)$$

$$R3 = \begin{cases} -10, & 0 \leq D_{O_in} < d_1 \\ -0.03, & d_1 \leq D_{O_in} < d_2 \\ 0, & D_{O_in} \geq d_2 \end{cases} \quad (6)$$

$$R4 = \begin{cases} -10, & 0 \leq D_{P_ij} < d_1 \\ -0.5, & d_1 \leq D_{P_ij} < d_2 \\ 0, & D_{P_ij} \geq d_2 \end{cases} \quad (7)$$

$$R5 = \begin{cases} -5, & 0 \leq D_{B_i} < r \\ 0, & D_{B_i} \geq r \end{cases} \quad (8)$$

$$R6 = \begin{cases} -0.5, & \Delta\psi = 90^\circ \\ -0.1, & \Delta\psi = 45^\circ \\ 0, & \Delta\psi = 0 \end{cases} \quad (9)$$

2 MADDPG 算法

2.1 算法介绍

在 USV 集群环境中, 每个 USV 作为独立智能体进行学习和策略更新, 环境因此呈现出动态不稳定性, 使算法收敛更加困难。传统强化学习难以适应这一环境, 且大量智能体交互增加了计算成本, 容易引发维度爆炸。为解决这些问题, 提出了 MADDPG 算法。每个 USV 在训练时, 中心化的 Critic 网络通过全局信息更新各智能体的 Q 值以提升策略稳定性; 在执行阶段, 去中心化的 Actor 网络基于局部观测独立决策, 提高了 USV 在复杂环境中的适应性。MADDPG 算法的框架如图 2 所示, 其中 $\{O_t^1, \dots, O_t^i, \dots, O_t^N\}$ 表示智能体在 t 时刻的观测信息, $\{a_t^1, \dots, a_t^i, \dots, a_t^N\}$ 表示智能体在 t 时刻的动作, $\{O_{t+1}^1, \dots, O_{t+1}^i, \dots, O_{t+1}^N\}$ 表示智能体在 $t+1$ 时刻的观测信息。




图 2 MADDPG 算法框架

Fig. 2 Framework of the MADDPG algorithm

MADDPG 算法环境中共有 N 个智能体, 智能体的策略 $\pi = \{\pi_1, \dots, \pi_i, \dots, \pi_N\}$, 智能体对应的策略参数 $\theta = \{\theta_1, \dots, \theta_i, \dots, \theta_N\}$, 则第 i 个智能体的累积期望奖励为

$$J(\theta_i) = E_{s \sim P^\pi, a_i \sim \pi_{\theta_i}} \left(\sum_{t=0}^{\infty} \gamma^t r_{i,t} \right) \quad (10)$$

式中: E^* 为误差, $*$ 为限定条件; S 为联合状态; P^π 为状态分布; $a_i = \{a_1, a_2, \dots, a_N\}$ 为联合动作;

π_{θ_i} 为动作分布; γ 为折扣因子; $r_{i,t}$ 为 t 时刻智能体的奖励。

$$\nabla_{\theta_i} J(\mu_i) = E_{x,a \sim D} [\nabla_{\theta_i} \mu_i(a_i | o_i) \nabla_{a_i} Q_i^{\mu}(x, a) |_{a_i = \mu_i(o_i)}] \quad (11)$$

式中: ∇_{θ_i} 表示对策略网络参数 θ_i 求梯度; $J(\mu_i)$ 表示以 μ_i 为策略的目标函数, 用于衡量策略的优劣; $\mu_i(a_i | o_i)$ 表示在观测 o_i 下, 策略 μ_i 选择动作 a_i 的概率; $Q_i^{\mu}(x, a)$ 表示状态-动作价值函数, 在策略 μ 下, 评估状态 x 和动作 a 的长期回报期望; D 为所有智能体的经验, 其中 D 中每个元素都是一个四元组 (x, a, r, x') , Critic 网络的更新方式借鉴了传统强化学习算法中的 TD-error 思想。利用预测值和目标值之间的误差来更新算法为

$$L(\theta_i) = E_{x,a,r,x'} \left[\left(Q_i^{\mu}(x, a) - y \right)^2 \right] \quad (12)$$

式中: $L(\theta_i)$ 为损失函数, 用于衡量价值函数估计值与目标值之间的差异; θ_i 为价值函数模型的参数, 训练的目标是通过调整 θ_i 来实现该损失函数最小化。

$$y = r_i + \gamma Q_i^{\mu'}(x', a'_1, a'_2, \dots, a'_n) |_{a_j = \mu_j'(o_j)} \quad (13)$$

式中: y 为价值网络更新的目标值; $Q_i^{\mu'}$ 为在策略 μ' 下的状态-动作价值函数, 用于评估从状态 x' 开始, 采取动作序列 $(a'_1, a'_2, \dots, a'_n)$ 后能获得的长期累计奖励期望, $\mu' = (\mu'_{\theta_1}, \mu'_{\theta_2}, \dots, \mu'_{\theta_n})$ 是具有延迟参数 θ'_i 的目标策略集合。

2.2 改进 MADDPG 算法

2.2.1 LSTM 单元引入

在 USV 集群中, MADDPG 算法通过为每个 USV 设计独立 Actor 网络和共享 Critic 网络来实现 USV 之间的协作。然而, MADDPG 在局部观测和历史信息捕捉上存在局限性, 主要表现在每个 USV 只能观测到部分环境信息, 无法获得所有 USV 的状态和动作, 由于 MADDPG 没有显式的记忆机制, 无法记录或回顾过往观测数据, 导致其在复杂、动态环境中难以有效捕捉长期依赖关系, 影响 USV 的任务协同。

为了解决上述问题, 通过引入 LSTM 单元, 帮助智能体在局部观测下积累过去的观测信息, 从而弥补因部分可观测性导致的信息缺失。MADDPG-LSTM 框架如图 3 所示。




图 3 MADDPG-LSTM 框架

Fig. 3 Framework of the MADDPG-LSTM algorithm

在 MADDPG-LSTM 框架中, L1 和 L2 分别嵌入于策略网络和价值网络中, 二者在功能上存在一定的差异。

L1(Actor 网络中的 LSTM): 用于捕捉动作生成过程中的时间依赖性, 通过积累自身观测数据和局部信息, 帮助 Actor 网络生成更符合长期目标的动作。具体表现在 USV 生成动作时, L1 结合历史状态和动作信息, 评估当前环境下最优行动路径, 从而提高协作效率。

L2(Critic 网络中的 LSTM): 用于辅助 Critic 网络在动态环境中更准确地评估动作的价值。通过结合历史信息, 预测 Q 值, 并指导学习者选择最优行动。具体表现在评估动作时, L2 不仅考虑当前状态, 还能参考过去几步的状态和动作, 提供更全局化的价值估计, 从而提升协作决策的稳健性。

该 MADDPG-LSTM 框架嵌入的 LSTM 单元, 通过门控机制选择性地保留有用的历史信息。在局部观测的限制下, LSTM 能够帮助 USV 记住前几步的状态和动作, 从而在当前步骤生成动作时参考这些历史信息; 再通过门控机制筛选出关键信息, 减少噪声干扰, 保持对关键状态和动作的记忆。因此, 该 MADDPG-LSTM 框架能显著提升 USV 之间的协作能力, 更好地适应动态复杂的策略空间。

2.2.2 多层次表征经验池设立

目前 MADDPG 算法采用单一经验池采样, 不同 USV 的经验可能互相干扰, 导致学习到的路径规划策略不稳定。单一经验池的均匀采样难以有效捕获各 USV 的关键决策经验, 导致算法对有助

于路径优化的经验数据利用不足, 影响模型的收敛速度和最终性能, 尤其是在稀疏奖励场景中, 重要经验可能频繁被忽略, 影响 USV 的协作效果。

为了解决上述问题, 引入多层级表征经验池采样机制至关重要。基于多层级经验池的 MADDPG-LSTM 框架如图 4 所示。




图 4 基于多层级经验池的 MADDPG-LSTM 算法框架
Fig. 4 Framework of MADDPG-LSTM algorithm based on multi-level buffer pool

该机制通过将经验池划分为“局部观测经验池”、“稀疏奖励经验池”以及“高价值 TD-error 经验池”, 根据 USV 的不同观测区域、任务阶段或经验类型分别存储经验数据, 各 USV 的不同任务经验不会互相干扰, 能够更加准确地学习到符合自身观测需求的策略, 提升路径规划的效率和稳定性。通过层级分层设计, 将重要经验分别存储在不同经验池中, 使得关键经验能够在特定池内得到更高的采样概率, 确保了 USV 能频繁学习到稀疏奖励环境中的高价值经验, 从而提升全局路径规划效果。

2.2.3 好奇心机制

MADDPG 算法通常面临稀疏奖励和有效探索效率低的问题。由于 USV 在海洋环境中执行复杂的协作任务, 路径规划任务中的复杂性和随机性也会增加任务难度, 使得其难以探索出新的高价值区域。为应对这些挑战, 在 MADDPG 算法中引入了 RND 机制^[16]。

图 5 展示了 RND 机制在强化学习中的流程, 包括如何为智能体生成内在奖励并优化其策略。在 RND 中, 通过 1 个目标网络和 1 个预测网络的

误差来计算奖励, 从而引导智能体在稀疏奖励或未知环境中进行有效探索。智能体在时刻 t 执行动作 a_t , 从而与环境交互, 生成新的观察值 O_{t+1} 。 O_{t+1} 经目标网络会根据目标网络参数 θ 生成目标特征 f_{t+1} , 预测网络会通过预测网络参数 θ' 生成预测特征 $\hat{f}_{t+1}$ 。内在奖励 r_t 通过计算 f_{t+1} 和 $\hat{f}_{t+1}$ 的误差获得 RND-MADDPG 伪代码见图 6, 计算公式为

$$r_t = |f_{t+1} - \hat{f}_{t+1}|^2 \quad (14)$$




图 5 随机网络蒸馏示意图
Fig. 5 Schematic diagram of random network distillation

- 1) 初始化每一个智能体的 Actor 网络和 Q 值 Critic 网络以及 RND 网络的目标网络和预测网络, 初始化 Replay Buffer
- 2) for episode=1 to N do
- 3) 对于每个智能体 i , 根据其策略网络 π 使用当前 state i 选择 action i 。将所有智能体的动作组合成 actions
- 4) 在环境中执行 actions, 得到 next state、外在奖励和完成标志 done。
- 5) 将 next state i 作为输入, 通过 RND 目标 i 和预测 i 计算内在奖励
- 6) 计算对每个智能体 i 的总奖励 total reward
- 7) 将 (state, actions, total rewards, next state) 存入经验回放池。
- 8) end for

图 6 RND-MADDPG 算法
Fig. 6 Algorithm of RND-MADDPG

3 仿真实验及分析

3.1 仿真环境设定

实验在 Windows 10 系统下进行, 开发平台为 Pycharm Community 2020.1 和 Anaconda3。仿真环境依托 OpenAI 平台搭建, 使用 Python 语言进行编程, 深度学习部分基于 Tensorflow 2.16.1 实现。首先, 构建 18×18 的二维栅格地图, 其中静态障碍物用黑色正方形表示, 3 个半径 $r=0.5$ 的圆形代表 3 个 USV, 其起始位置不同, 同时 3 个援救目标点用五角星表示。文中设置 USV 的数量与目标点的数量相一致, 不考虑任务分配中的竞争关系, 而是每个

USV 都有一个对应的目标。实验设定的训练参数如表 1 所示。实验中, USV 的训练设定为 10 000 回合, 每回合最多训练 100 步。其中设置到达目标点的判定阈值为 0.5, 即当 USV 的质心距离目标点小于或等于 0.5 时, 即认为成功抵达。USV 会在地图中持续探索与学习, 当满足以下任一条件时, 会触发场景重置, 开启新的训练回合: 1) 成功到达目标点; 2) 与障碍物发生碰撞; 3) 单回合训练步数超过 100 步。

表 1 实验超参数

Table 1 Experimental hyperparameters

参数名称	数值
经验池大小	10 000
Actor网络学习率	0.001
Critic网络学习率	0.001
训练回合数	10 000
批尺寸	1 024
折损因子 γ	0.99
软更新系数 τ	0.01
每回合最大步数	100

3.2 实验与分析

为了实现 USV 集群在面向海上救援任务中的联合搜救, 每艘 USV 需要独立导航至目标点, 在寻径的过程中, 需要避开障碍物和其他 USV, 使 USV 以最少的碰撞次数、最少的时间步和尽可能小的航向角变化到达目标点, 其中最大奖励以及收敛速度为衡量该策略优劣性的重要指标。为了实现联合搜救, 每艘 USV 对所抵达哪个目标点进行判断, 尽量避免多个 USV 抵达同一个目标点, 这要求算法具备良好的多智能体协调能力, 确保任务能够在合理的时间内完成。

将原始 MADDPG 算法与文中改进 MADDPG-LSTM 算法、MADDPG-LSTM-多经验池算法以及 MADDPG-LSTM-RND-多经验池算法, 在相同实验环境下进行对比测试, 通过协同合作与任务分配, 来实现对 USV 集群的路径规划以及评估其在复杂环境下不同算法的性能表现, 不同算法获得最大奖励时的路径规划效果图如图 7~图 11 所示。

针对收敛速度而言, 其衡量的是算法达到最优策略所需的训练时间或步数, 收敛速度越快, 说明




图 7 MADDPG 算法最大奖励时的路径
Fig. 7 Path at maximum reward by the MADDPG algorithm




图 8 MADDPG-LSTM 算法最大奖励时的路径
Fig. 8 Path at maximum reward by the MADDPG-LSTM algorithm




图 9 多层级经验池 MADDPG-LSTM 算法最大奖励时的路径
Fig. 9 Path at maximum reward based on multi-level experience pool MADDPG-LSTM algorithm




图 10 多层级经验池 MADDPG-LSTM-RND 算法最大奖励时的路径

Fig. 10 Path at maximum reward based on multi-level experience pool MADDPG-LSTM-RND algorithm




图 11 不同算法奖励图

Fig. 11 Reward graphs for different algorithms

算法解决问题的效率越高。原始的 MADDPG 算法大约需要 6 500 次迭代才能收敛。其收敛曲线

在初期有较大的波动,收敛过程波动较大,且收敛效果也不稳定,说明 USV 在寻找稳定策略的过程中耗费了更多的时间。改进的 MADDPG-LSTM 算法,通过 LSTM 的引入加快了模型对时序信息的学习,因此收敛速度略有提升。多经验池能够有效加速学习过程,进一步提高收敛速度,表现出较强的学习能力。基于多层级经验池 MADDPG-LSTM-RND 算法在迭代次数上表现出明显优势,约 4 000 次迭代后趋于收敛,这可能得益于 RND 的引入,它促进了算法对环境的快速适应。相比原始 MADDPG 算法收敛速度提高了 38.46%。

最大奖励反映算法的最优表现,奖励值越高表示路径规划的效果越好。根据奖励函数的设计,其转弯次数、总步长以及靠近障碍物的次数都对最终的奖励有着较大的影响,如表 2 所示。由于原始的 MADDPG 算法规划的路径较长以及转弯次数较多,导致奖励降低。引入 LSTM 后,最大奖励提升至 25.85,生成的路径规划更为平滑,改善了路径规划的质量。通过增加多层级经验池机制,最大奖励进一步提升至 26.25,使 USV 能更有效地避开障碍,生成的路径长度也更短,提升了路径规划效率。基于多层级经验池 MADDPG-LSTM-RND>算法最大奖励达到 27.45,显示 RND 的引入有效加速了智能体的学习过程。这表明改进的 MADDPG 算法能够在相同的环境条件下有效避开障碍物、缩短路径长度,并且尽量减少航向角变化,从而获得了更高的奖励值。

表 2 不同算法规划最优路径性能表现

Table 2 Performance of different algorithms for planning out the optimal paths

算法	最大奖励值	到达所有目标点收敛回合	规划路径与障碍物相邻次数	转弯次数	到达所有目标点总步数
MADDPG	23.25	6 500	82	25	18.5
MADDPG-LSTM	25.85	5 500	73	20	21.0
多层级经验池	26.25	4 500	65	20	17.5
MADDPG-LSTM	26.25	4 500	65	20	17.5
多层级经验池 MADDPG-LSTM-RND	27.45	4 000	53	21	13.5

总而言之,基于多层级经验池 MADDPG-LSTM-RND 算法相较于原始 MADDPG 算法,收敛速度明显提升了 38.46%,全局最大奖励提高了 18.06%,路径长度也缩短了 27.02%。

4 结束语

针对 USV 集群的海上救援路径规划问题,提

出了一种改进的 MADDPG 算法。仿真实验结果表明,基于多层级经验池 MADDPG-LSTM-RND 算法提供了最佳的协同路径规划策略,能够有效减少碰撞,提高路径规划效率,同时保持航向的平稳性,是最适合应用于 USV 集群海上救援任务的方案。

未来可在该算法的基础上进一步优化,考虑动

态障碍物以及动态目标点下的场景, 以进一步提高路径规划效率和智能体的协作能力。

参考文献:

- [1] 肖乾治, 陈大力, 殷昭鲁. 新时代发展海洋经济建设海洋强国思考[J]. *商业经济*, 2023(8): 5-7.
- [2] 费陈, 贺拥亮, 赵亮, 等. 面向海上复杂环境的无人艇集群航迹规划发展综述[J]. *电讯技术*, 2024, 11(3): 1-11.
- [3] 陈羽, 褚天仁. 水面无人艇路径规划研究现状[J]. *科技创新与应用*, 2024, 14(6): 84-87.
- [4] 唐杭斌. 水面无人艇研究现状与发展趋势[J]. *船舶物资与市场*, 2020(3): 13-14.
- [5] CHU Y J, GAO Q Z, YUE Y, et al. Evolution of unmanned surface vehicle path planning: A comprehensive review of basic, responsive, and advanced strategic pathfinders[J]. *Drones*, 2024, 8(10): 540.
- [6] 王秀玲, 尹勇, 赵延杰, 等. 无人艇海上搜救路径规划技术综述[J]. *船舶工程*, 2023, 45(4): 50-57.
WANG X L, YIN Y, ZHAO Y J, et al. Overview of USV maritime search and rescue path planning technology[J]. *Ship Engineering*, 2023, 45(4): 50-57.
- [7] DIJKSTRA E W. A note on two problems in connexion with graphs[J]. *Numerische Mathematik*, 1959, 1(1): 269-271.
- [8] HART P E, NILSSON N J, RAPHAEL B. A formal basis for the heuristic determination of minimum cost paths[J]. *IEEE transactions on Systems Science and Cybernetics*, 1968, 4(2): 100-107.
- [9] HOLLAND J H. Adaptation in natural and artificial systems: An introductory analysis with applications to biology, control, and artificial intelligence[M]. Cambridge, USA: MIT Press, 1992.
- [10] DORIGO M, DI CARO G, GAMBARDELLA L M. Ant algorithms for discrete optimization[J]. *Artificial Life*, 1999, 5(2): 137-172.
- [11] RAIBAIL M, RAHMAN A H, AL-ANIZY G J, et al. Decentralized multi-robot collision avoidance: A systematic review from 2015 to 2021[J]. *Symmetry*, 2022, 14(3): 610.
- [12] LI Y, LI X W, WEI X W, et al. Sim-real joint experimental verification for an unmanned surface vehicle formation strategy based on multi-agent deterministic policy gradient and line of sight guidance[J]. *Ocean Engineering*, 2023, 270: 113661.
- [13] LOWEN R, WU Y, TAMAR A, et al. Multi-agent actor-critic for mixed cooperative-competitive environments [C]//Proc of the 31st Int Conf on Neural Information Processing Systems. Cambridge, USA: MIT, 2017: 6382-6393.
- [14] 王思琪, 关巍, 佟敏, 等. 基于 ATMADDPG 算法的多水面无人航行器编队导航[J]. *吉林大学学报(信息科学版)*, 2024, 42(4): 588-599.
WANG S Q, GUAN W, TONG M, et al. Formation navigation of multi-unmanned surface vehicles based on ATMADDPG algorithm[J]. *Journal of Jilin University (Information Science Edition)*, 2024, 42(4): 588-599.
- [15] 刘鹏, 赵建新, 张宏映, 等. 基于改进型 MADDPG 的多智能体对抗策略算法[J]. *火力与指挥*, 2023, 48(3): 132-138.
LIU P, ZHAO J X, ZHANG H Y, et al. Multi-agent confrontation strategy algorithm based on improved MADDPG[J]. *Fire Control & Command Control*, 2023, 48(3): 132-138.
- [16] LU R Z, HONG S. Incentive-based demand response for smart grid with reinforcement learning and deep neural network[J]. *Applied Energy*, 2019, 236: 937-949.

(责任编辑: 许妍)

(上接第 340 页)

- [10] SUI B W, ZHANG J Q, LIU Z. Prescribed-time dynamic positioning control for USV with lumped disturbances, thruster saturation and prescribed performance constraints[J]. *Remote Sensing*, 2024, 16(22): 4142.
- [11] WANG Y, YANG X, HAO L Y, et al. Integral sliding mode output feedback control for unmanned marine vehicles using T-S fuzzy model with unknown premise variables and actuator faults[J]. *Journal of Marine Science and Engineering*, 2024, 12(6): 920.
- [12] ZHANG Y Y, ZHANG J Q, SUI B. Robust fixed-time adaptive fault-tolerant control for dynamic positioning of ships with thruster faults[J]. *Applied Sciences*, 2024, 14(13): 5738.
- [13] HAO L Y, ZHANG H, GUO G, et al. Quantized sliding mode control of unmanned marine vehicles: Various thruster faults tolerated with a unified model[J]. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2021, 51(3): 2012-2026.
- [14] WANG N, DENG Z C. Finite-time fault estimator based fault-tolerance control for a surface vehicle with input saturations[J]. *IEEE Transactions on Industrial Informatics*, 2019, 16(2): 1172-1181.
- [15] CHRISTOFIDES P D, LIU J, DE L P D M. Networked and distributed predictive control: methods and nonlinear process network applications[M]. New York, USA: Springer Science & Business Media, 2011.
- [16] KHALIL H K. Nonlinear systems[M]. New York, USA: Prentice-Hall, 1996.

(责任编辑: 靳潇倩)